

Model Risk & Data Science Training

CaixaBank · Advanced Analytics Program

Sergi Ramirez Mitjans



ESTUDIOS

Grau en Estadística. Universitat de Barcelona (UB) i Universitat Politècnica de Catalunya (UPC)

Postgrau en Data Science i Big Data. Universitat de Barcelona (UB)


Máster en Data Science. Universitat Oberta de Catalunya (UOC)

Doctorando en Inteligencia Artificial. Universitat Politècnica de Catalunya (UPC)



TRABAJO

SALUD



SPORT ANALYTICS



MARKETING ANALYTICS



CONSULTORIA



DOCÈNCIA



	DIA 1	DIA 2	DIA 3
08:00 - 08:30			
08:30 - 09:00		RECAPITULACIÓN + CORRECCIÓN DE EJERCICIOS	RECAPITULACIÓN + CORRECCIÓN DE EJERCICIOS
09:00 - 09:30			
09:30 - 10:00			
10:00 - 10:30	MODELOS SUPERVISADOS	BOOSTING MODELS: XGBOOST	DEEP LEARNING: CONVOLUTIONAL NEURAL NETWORK (CNN)
10:30 - 11:00			
11:00 - 11:30	MODELOS LINEALES GENERALIZADOS (GLM) - MODELO LOGÍSTICO	DESCANSO	DESCANSO
11:30 - 12:00		SUPPORT VECTOR MACHINE (SVM)	DEEP LEARNING: CONVOLUTIONAL NEURAL NETWORK (CNN)
12:00 - 12:30	DESCANSO		CASOS REALES DE NEGOCIO
12:30 - 13:00	ÁRBOLES DE DECISIÓN	EVALUACIÓN E INTERPRETABILIDAD DE MODELOS	
13:00 - 13:30			CIERRE DEL WORKSHOP
13:30 - 14:00	COMIDA	COMIDA	
14:00 - 14:30			
14:30 - 15:00	ÁRBOLES DE DECISIÓN	DEEP LEARNING: ARTIFICIAL NEURAL NETWORK (ANN)	
15:00 - 15:30			
15:30 - 16:00	DESCANSO		
16:00 - 16:30	BAGGING MODELS: RANDOM FOREST	DESCANSO	
16:30 - 17:00		DEEP LEARNING: ARTIFICIAL NEURAL NETWORK (ANN)	
17:00 - 17:30			



01

Regresión Logística (GLM)

03

Random Forest

05

Support Vector Machine (SVM)

07

Redes Neuronales Artificiales (ANN)

09

Transfer Learning

02

Árboles de Decisión

04

Boosting: AdaBoost · XGBoost · CatBoost

06

Evaluación e Interpretación de Modelos


08

Redes Neuronales Convolucionales (CNN)

10

End-to-End: Aplicación del Modelaje

1. Modelos supervisados



CaixaBank




UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

Proceso de construcción de modelos de Machine Learning



Definición del problema y obtención de los datos




Ingeniería de características y selección del modelo



División de datos de entrenamiento, evaluación y entrenamiento del modelo



Validación del modelo e interpretación de resultados



Implementar y mejorar el modelo

Explicación

El desarrollo de un modelo de ML es un proceso complejo que incluye

- Evaluación y preparación adecuada de los datos
- Construcción del modelo con preparación de conjunto de datos y validación de su calidad

Se utilizan dos marcos de trabajo:

- KDD
- CRISP-DM como proceso cíclico:




CaixaBank



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

Knowledge Discovery Databases (KDD)



Tipos de Machine Learning

**Aprendizaje
Supervisado**

**Aprendizaje no
Supervisado**

**Aprendizaje
semi-supervisado**

**Aprendizaje por
refuerzo**

Entrenamiento con
datos etiquetados
(entrada + salida)

Entrenamiento con
datos no
etiquetados

Combinación de
datos etiquetados y
datos no
etiquetados

Aprendizaje a
través de la
interacción con el
entorno y el
feedback
(recompensa/
castigo)




CaixaBank



**UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH**

Modelos de Machine Learning



¿Que tener en cuenta?



¿Que tener en cuenta?

La decisión dicotomía



GLMs

ÁRBOLES DE
DECISIÓN

RANDOM
FOREST

XGBOOST,
CATBOOST,
ADABOOST

SVM

DEEP
LEARNING

Data Engineering


Evaluación de modelos: Train, Test y cross-validation

Vertical data

	Variables				
Cases					

Horizontal data

	Variables									
Cases										




CaixaBank



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH


Data Engineering

Evaluación de modelos: Train, Test y cross-validation



Data Engineering


Evaluación de modelos: Train, Test y cross-validation



Data Engineering

Evaluación de modelos: Train, Test y cross-validation

El sobre-ajustamiento (**overfitting**) es una característica de los modelos que se produce cuando el modelo se ajusta mucho a los datos de entrenamiento, pero tiene un rendimiento deficiente al predecir nuevos datos:



Data Engineering

Evaluación de modelos: Train, Test y cross-validation

- Un modelo con sobre-ajustamiento predirá de forma deficiente observaciones futuras
- Habitualmente pasa en modelos excesivamente complejos que no generalizan bien más allá de los datos de entrenamiento.

Data Engineering

Datos Desbalanceados

Un dataset está desbalanceado cuando una clase aparece mucho más que otra

Ejemplo:

Clase mayoritaria

95%



Clase minoritaria

5%



¿POR QUÉ ES UN PROBLEMA?



El modelo se sesga hacia la clase mayoritaria.



Puede tener alta accuracy pero mal rendimiento real.



Difícil detectar la clase minoritaria (la importante muchas veces).




CaixaBank



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

Data Engineering

Estrategias para combatir el desbalanceo



2. Modelos lineales generalizados




CaixaBank





UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

Regresión Logística

- Herramienta eficaz para la clasificación de dos clases y multiclases
- Es rápida y sencilla
- Proporciona límites de clase lineal








El principal problema es que se podrían obtener valores sin sentido para $\hat{y}$. Dado que se está modelando $P(y = 1)$, los valores de $\hat{y}$ inferiores a 0 y superiores a 1 estarían en desacuerdo con la medida natural de $\hat{y}$. La regresión lineal puede dar lugar a este problema.

Regresión Logística

La regresión logística aborda el problema de estimar una probabilidad, $P(y = 1)$, de estar fuera del rango de $[0, 1]$. El modelo de regresión logística utiliza una función, llamada función logística, para modelar $P(y = 1)$



$$P(Y = 1) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

Regresión Logística

El modelo logístico se puede reescribir como:

$$\ln \left(\frac{P(Y = 1)}{1 - P(Y = 1)} \right) = \beta_0 + \beta_1 X$$

La regresión logística modela las probabilidades logarítmicas con una función lineal de los predictores o características, X . Esto nos da la interpretación natural de las estimaciones similar a la regresión lineal: un cambio de una unidad en X está asociado con un cambio de β en las probabilidades logarítmicas de éxito ($Y = 1$); o mejor aún, un cambio de una unidad en X está asociado con un cambio multiplicado de e^{β_1} en las probabilidades de éxito ($Y = 1$).


Regresión Logística

Los **odds** son la razón entre la probabilidad de que un evento ocurra (p) y la de que no ocurra ($1 - p$) calculada como $\frac{p}{1-p}$

Indica cuántas veces es más probable que el evento ocurra a que no ocurra.

Ejemplo: Si la probabilidad de ganar es 0.8, el odds es de: $\frac{0,8}{1-0,8} = 4$

Significa que hay 4 veces más posibilidades de ganar que de perder.



Regresión Logística

El *odds ratio* o razón de odds (*OR*) compara dos odds para medir la fuerza de asociación entre dos variables.

$OR = 1$: No hay asociación entre los grupos y el evento

$OR > 1$: El factor aumenta la probabilidad de que ocurra el evento (factor de riesgo)

$OR < 1$: El factor reduce la probabilidad de que ocurra el evento (factor de protector)

Ejemplo: Un *OR* de 3 indica que el grupo expuesto tiene 3 veces más chances de presentar el desenlace que el grupo de referencia.

3. Árboles de decisión





CaixaBank





UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH



Árboles, Bosques y Selvas

- Subdividen el espacio de características en regiones con casi siempre la misma etiqueta
- Un árbol de decisión subdivide un espacio de características en regiones de valores más o menos uniformes
- Los bosques de decisión pueden llegar a usar demasiada memoria










Árboles de decisión

Proporcionan un conjunto de reglas que se van aplicando sobre los ejemplos nuevos para decidir qué clasificación es la más adecuada a sus atributos.

Predictors				Target
Outlook	Temp	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No



Árboles de decisión

Un **árbol de decisión** está formado por un conjunto de nodos de decisión (interiores) y de nodos-respuesta (hojas):

- Un **nodo de decisión** está asociado a uno de los atributos y tiene 2 o más ramas que salen de él, cada una de ellas representando los posibles valores que puede tomar el atributo asociado. De alguna forma, un nodo de decisión es como una pregunta que se le hace al ejemplo analizado, y dependiendo de la respuesta que de, el flujo tomará una de las ramas salientes.
- Un **nodo-respuesta** está asociado a la clasificación que se quiere proporcionar, y nos devuelve la decisión del árbol con respecto al ejemplo de entrada.

Árboles de decisión: ID3

- 1979, J. Ross Quinlan
- Usa **Teoría de la Información** (C. Shannon, 1948)
- Construye un árbol de decisión de arriba a abajo, de forma directa, sin backtracking, y basándose únicamente en los ejemplos iniciales proporcionados
- Usa el concepto de **Ganancia de Información** para seleccionar el atributo más útil en cada paso:
 - **Entropía de Shannon**, que de alguna forma mide el grado de incertidumbre de una muestra

Árboles de decisión: ID3 - Entropía


- Mide el grado de incertidumbre de una muestra:
- Una muestra completamente homogénea tiene entropía 0.
- Una muestra igualmente distribuida tiene entropía 1.
- En general, la fórmula de la entropía es:

$$E(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

Play Golf	
Yes	No
9	5



$$\begin{aligned} \text{Entropy(PlayGolf)} &= \text{Entropy}(5,9) \\ &= \text{Entropy}(0.36, 0.64) \\ &= -(0.36 \log_2 0.36) - (0.64 \log_2 0.64) \\ &= 0.94 \end{aligned}$$



- Por ejemplo: $E(s) = -P \log_2 (P) - N \log_2 (N)$, donde P son los ejemplos positivos y N los negativos.

Árboles de decisión: ID3 – Ganancia Información

- La **Ganancia de Información** se basa en el decremento de la entropía cuando el conjunto de datos se divide en los valores de un atributo.
- ¿Qué atributo crea las ramas más homogéneas?
 - Calcular la entropía del total.
 - Dividir el conjunto de datos en función de los diferentes atributos.

Árboles de decisión: ID3 – Ganancia Información

- La **Ganancia de Información** se basa en el decremento de la entropía cuando el conjunto de datos se divide en los valores de un atributo.
- ¿Qué atributo crea las ramas más homogéneas?
 - Calcular la entropía de cada rama, y sumar proporcionalmente las ramas para calcular la entropía del total.
 - Restar este resultado de la entropía original.
 - El resultado es la Ganancia de Información (descenso de entropía).
 - El atributo con mayor Ganancia es selecciona como nodo de decisión.

$$Gain(S, A) = Entropia(S) - \sum_{v \in \text{valores}(A)} \frac{|S_v|}{|S|} Entropia(S_v)$$

Árboles de decisión: ID3 – Ganancia Información

- Una rama con entropía 0 se convierte en hoja (todos sus casos están ya clasificados).
- Si no es así, la rama debe seguir subdividiéndose (para poder clasificar mejor sus nodos).
- El algoritmo ID3 se ejecuta recursivamente en nodos que no son hojas, hasta que se llegue a nodos-hoja.

Árboles de decisión: ID3 – Ejemplo Completo

Predictors				Target
Outlook	Temp.	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No

Play Golf	
Yes	No
9	5

1^o

$$\begin{aligned}
 \text{Entropy(PlayGolf)} &= \text{Entropy}(5,9) \\
 &= \text{Entropy}(0.36, 0.64) \\
 &= -(0.36 \log_2 0.36) - (0.64 \log_2 0.64) \\
 &= 0.94
 \end{aligned}$$

2^o

$$E(T, X) = \sum_{c \in X} P(c)E(c)$$

		Play Golf		
		Yes	No	
Outlook	Sunny	3	2	5
	Overcast	4	0	4
	Rainy	2	3	5
				14

↓

$$\begin{aligned}
 E(\text{PlayGolf}, \text{Outlook}) &= P(\text{Sunny}) \cdot E(3,2) + P(\text{Overcast}) \cdot E(4,0) + P(\text{Rainy}) \cdot E(2,3) \\
 &= (5/14) \cdot 0.971 + (4/14) \cdot 0.0 + (5/14) \cdot 0.971 \\
 &= 0.693
 \end{aligned}$$



Árboles de decisión: ID3 – Ejemplo Completo

Predictors				Target
Outlook	Temp.	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No

		Play Golf	
		Yes	No
Outlook	Sunny	3	2
	Overcast	4	0
	Rainy	2	3
		Gain = 0.247	

30

		Play Golf	
		Yes	No
Temp.	Hot	2	2
	Mild	4	2
	Cool	3	1
		Gain = 0.029	

		Play Golf	
		Yes	No
Humidity	High	3	4
	Normal	6	1
		Gain = 0.152	

		Play Golf	
		Yes	No
Windy	False	6	2
	True	3	3
		Gain = 0.048	

$$Gain(T, X) = Entropy(T) - Entropy(T, X)$$

$$G(\text{PlayGolf}, \text{Outlook}) = E(\text{PlayGolf}) - E(\text{PlayGolf}, \text{Outlook})$$

$$= 0.940 - 0.693 = 0.247$$

		Play Golf	
		Yes	No
★ Outlook	Sunny	3	2
	Overcast	4	0
	Rainy	2	3
		Gain = 0.247	

40



CaixaBank




UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH


Árboles de decisión: ID3 – Ejemplo Completo

		Play Golf	
		Yes	No
★ Outlook	Sunny	3	2
	Overcast	4	0
	Rainy	2	3
Gain = 0.247			

50





Temp.	Humidity	Windy	Play Golf
Mild	High	FALSE	Yes
Cool	Normal	FALSE	Yes
Mild	Normal	FALSE	Yes
Cool	Normal	TRUE	No
Mild	High	TRUE	No



repetir

...repetir...

Árboles de decisión: ID3 – Ejemplo Completo



Árboles de decisión: ID3 – Ejemplo Completo

R_1 : IF (Outlook=Sunny) AND (Windy=FALSE) THEN Play=Yes


R_2 : IF (Outlook=Sunny) AND (Windy=TRUE) THEN Play=No

R_3 : IF (Outlook=Overcast) THEN Play=Yes

R_4 : IF (Outlook=Rainy) AND (Humidity=High) THEN Play=No

R_5 : IF (Outlook=Rain) AND (Humidity=Normal) THEN Play=Yes

Árbol de decisión



Obtención de reglas interpretables

4. Bagging models: Random Forest




CaixaBank



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

Bagging



Random Forest

Random Forest es una forma modificada de *bagging* que crea conjuntos de árboles de decisión independientes.

Para descorrelacionar los árboles, hacemos lo siguiente:

1. Entrenamos cada árbol con una muestra bootstrap separada del conjunto de entrenamiento completo (igual que en bagging).
2. Para cada árbol, en cada división, seleccionamos aleatoriamente un conjunto de predictores J' del conjunto completo de predictores. De entre los predictores J' , seleccionamos el predictor óptimo y el umbral óptimo correspondiente para la división.

Random Forest

Los modelos de Random Forest tienen múltiples hiperparámetros para ajustar:

1. el número de predictores que se seleccionan aleatoriamente en cada división
2. el número total de árboles en el conjunto
3. la profundidad máxima o el tamaño mínimo del nodo hoja En teoría, cada árbol en el bosque aleatorio está completo, pero en la práctica esto puede ser computacionalmente costoso (y agregar redundancias en el modelo), por lo que imponer un tamaño mínimo de nodo o `max_depth` no es inusual.

Random Forest

Los modelos de Random Forest tienen múltiples hiperparámetros para ajustar:

1. el número de predictores que se seleccionan aleatoriamente en cada división
2. el número total de árboles en el conjunto
3. la profundidad máxima o el tamaño mínimo del nodo hoja En teoría, cada árbol en el bosque aleatorio está completo, pero en la práctica esto puede ser computacionalmente costoso (y agregar redundancias en el modelo), por lo que imponer un tamaño mínimo de nodo o `max_depth` no es inusual.

End the day 1

5. Boosting models: XGBoost, AdaBoost, CatBoost



CaixaBank



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH



CaixaBank

¡Gracias!

sergi.ramirez@upc.edu